

RKNN3 SDK Release Note

文件标识：RK-JC-YF-429

发布版本：V1.1.0

日期：2026-08-19

文件密级：☐绝密 ☐秘密 ☐内部资料 ☒公开

免责声明

本文档按“现状”提供，瑞芯微电子股份有限公司（“本公司”，下同）不对本文档的任何陈述、信息和内容的准确性、可靠性、完整性、适销性、特定目的性和非侵权性提供任何明示或暗示的声明或保证。本文档仅作为使用指导的参考。

由于产品版本升级或其他原因，本文档将可能在未经任何通知的情况下，不定期进行更新或修改。

商标声明

“Rockchip”、“瑞芯微”、“瑞芯”均为本公司的注册商标，归本公司所有。

本文档可能提及的其他所有注册商标或商标，由其各自拥有者所有。

版权所有 © 2026 瑞芯微电子股份有限公司

超越合理使用范畴，非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

瑞芯微电子股份有限公司

Rockchip Electronics Co., Ltd.

地址：福建省福州市铜盘路软件园A区18号

网址：www.rock-chips.com

客户服务电话：+86-4007-700-590

客户服务传真：+86-591-83951833

客户服务邮箱：fae@rock-chips.com

读者对象

本文档（本指南）主要适用于以下工程师：

技术支持工程师

软件开发工程师

修订记录

版本	修改人	修改日期	修改说明	核定人
V0.2.0	HPC	2025-08-16	初始版本	熊伟
V0.3.0b0	HPC	2025-09-12	1. 更新支持的模型列表 2. 更新精度、性能数据	熊伟
V0.4.0b0	HPC	2025-11-03	1. 更新支持的模型列表 2. 更新概述、精度、性能数据	熊伟
V1.0.0	HPC	2026-01-23	1. 更新支持的模型列表 2. 更新精度、性能数据	熊伟
V1.0.4	HPC	2026-05-15	1. 更新支持的模型列表 2. 更新精度、性能数据 3. 更新支持的硬件平台	熊伟
V1.1.0	HPC	2026-08-19	1. 更新支持的模型列表 2. 更新精度、性能数据	熊伟

目录

RKNN3 SDK Release Note

1 概述

1.1 支持的硬件平台

1.2 支持的系统

2 主要特性

3 支持的模型

4 模型性能

5 模型精度

6 服务器配置推荐

7 参考

7.1 性能测试方法

7.2 精度测试方法

1 概述

RKNN3 SDK提供了AI模型部署到RK1820/RK1828和RK3572所需要的软件栈，包括PC端开发套件（RKNN3 Toolkit）、板端运行API（RKNN3 Runtime）以及模型转换部署示例（RKNN3 Model Zoo）等。本次发布的SDK支持协处理器模式（RK1820/1828）和非协处理器模式（RK3572），两种模式的主要区别如下：

[协处理器模式（RK182X）]

- **主控SoC**：作为系统核心，负责任务调度、资源分配和整体控制
- **RK1820/1828协处理器**：作为AI计算加速单元，专注于高性能神经网络推理任务
- **PCIe/USB高速接口**：实现主控与协处理器之间的低延迟、高带宽数据交互

[非协处理器模式（RK3572）]

- **RK3572 SoC**：集成高性能NPU的SoC平台，支持直接运行AI推理任务
- **统一内存架构**：NPU与CPU/GPU共享内存空间

1.1 支持的硬件平台

- RK1820/RK1828 协处理器
- RK3572

1.2 支持的系统

- Android/Linux/Windows

2 主要特性

- 新增 RK182X 多卡级联支持
- 新增 Qwen3.5 模型支持
- 新增 Qwen3.5 和 Gemma-4 的 Prefix Caching 支持
- 新增自定义 CPU 算子支持
- 新增多 Session 设置不同上下文长度的支持，满足不同会话的使用需求
- 新增 Tie Word Embedding 支持
- 新增 RKNN3 Toolkit 对 macOS 平台的支持（Beta）
- 优化 KVCache 导入和导出过程中的 Host 端内存占用
- 优化 `rknn3_mem_sync` 接口性能
- 优化 GRQ 量化过程中的 GPU 显存占用
- 更新外部 GRQ 量化的使用方式
- 调整 RKNN3 Toolkit 模型导入方式：统一使用 ONNX（移除 TensorFlow/TFLite/Caffe/DarkNet 支持）

3 支持的模型

目前支持的模型包括但不限于以下列表：

LLM（大语言模型）

模型名称	模型来源
Qwen2.5-0.5B	https://huggingface.co/Qwen/Qwen2.5-0.5B
Qwen2.5-1.5B	https://huggingface.co/Qwen/Qwen2.5-1.5B
Qwen2.5-3B	https://huggingface.co/Qwen/Qwen2.5-3B-Instruct
Qwen2.5-7B	https://huggingface.co/Qwen/Qwen2.5-7B-Instruct
Qwen3-0.6B	https://huggingface.co/Qwen/Qwen3-0.6B
Qwen3-1.7B	https://huggingface.co/Qwen/Qwen3-1.7B
Qwen3-4B	https://huggingface.co/Qwen/Qwen3-4B
Qwen3-8B	https://huggingface.co/Qwen/Qwen3-8B
Qwen3.5-0.8B	https://huggingface.co/Qwen/Qwen3.5-0.8B
Qwen3.5-2B	https://huggingface.co/Qwen/Qwen3.5-2B
Qwen3.5-4B	https://huggingface.co/Qwen/Qwen3.5-4B
Qwen3.5-9B	https://huggingface.co/Qwen/Qwen3.5-9B
Qwen3.5-27B	https://huggingface.co/Qwen/Qwen3.5-27B
Qwen3.8-27B	https://huggingface.co/Qwen/Qwen3.8-27B
Youtu-LLM-2B	https://huggingface.co/tencent/Youtu-LLM-2B
GLM-Edge-1.5B-Chat	https://modelscope.cn/models/ZhipuAI/glm-edge-1.5b-chat
MiniCPM5-1B	https://huggingface.co/openbmb/MiniCPM5-1B
FunctionGemma-270M	https://huggingface.co/google/functiongemma-270m-it
LFM2.5-1.2B	https://huggingface.co/LiquidAI/LFM2.5-1.2B-Instruct

VLM（视觉语言模型）

模型名称	模型来源
Qwen2.5-VL-3B	https://huggingface.co/Qwen/Qwen2.5-VL-3B-Instruct
Qwen2.5-VL-7B	https://huggingface.co/Qwen/Qwen2.5-VL-7B-Instruct
Qwen3-VL-2B	https://huggingface.co/Qwen/Qwen3-VL-2B-Instruct
Qwen3-VL-4B	https://huggingface.co/Qwen/Qwen3-VL-4B-Instruct
FastVLM-1.5B	https://github.com/apple/ml-fastvlm
InternVL3-2B	https://huggingface.co/OpenGVLab/InternVL3-2B
InternVL3_5-4B	https://huggingface.co/OpenGVLab/InternVL3_5-4B-Instruct
MiniCPM-V-4	https://huggingface.co/openbmb/MiniCPM-V-4
MiMo-VL-7B-RL	https://huggingface.co/XiaomiMiMo/MiMo-VL-7B-RL
LocateAnything-3B	https://huggingface.co/nvidia/LocateAnything-3B
SmolVLM-500M-Instruct	https://huggingface.co/HuggingFaceTB/SmolVLM-500M-Instruct
SmolVLM2-500M-Video-Instruct	https://huggingface.co/HuggingFaceTB/SmolVLM2-500M-Video-Instruct
UI-TARS-2B-SFT	https://huggingface.co/ByteDance-Seed/UI-TARS-2B-SFT
gme-Qwen2-VL-2B-Instruct	https://huggingface.co/Alibaba-NLP/gme-Qwen2-VL-2B-Instruct

全模态模型（Omni）

模型名称	模型来源
Qwen2.5-Omni-3B (Thinker)	https://huggingface.co/Qwen/Qwen2.5-Omni-3B
Qwen3-Omni	商业闭源模型
Qwen3.5-Omni	商业闭源模型
Gemma-4-E2B	https://huggingface.co/google/gemma-4-E2B-it
Gemma-4-E4B	https://huggingface.co/google/gemma-4-E4B-it
Gemma-4-12B	https://huggingface.co/google/gemma-4-12B-it
Gemma-4-31B	https://huggingface.co/google/gemma-4-31B-it

语音识别（ASR）

模型名称	模型来源
Qwen3-ASR-0.6B	https://huggingface.co/Qwen/Qwen3-ASR-0.6B
Whisper	https://huggingface.co/openai/whisper-large-v3
SenseVoiceSmall	https://modelscope.cn/models/iic/SenseVoiceSmall
Zipformer	https://huggingface.co/pfluo/k2fsa-zipformer-chinese-english-mixed

语音合成（TTS）

模型名称	模型来源
Qwen3-TTS-12Hz-1.7B	https://huggingface.co/Qwen/Qwen3-TTS-12Hz-1.7B-Base
VITS	https://github.com/jaywalnut310/vits

Embedding / Reranker

模型名称	模型来源
Qwen3-Embedding-0.6B	https://huggingface.co/Qwen/Qwen3-Embedding-0.6B
Qwen3-Embedding-4B	https://huggingface.co/Qwen/Qwen3-Embedding-4B
Qwen3-Reranker-0.6B	https://huggingface.co/Qwen/Qwen3-Reranker-0.6B
Qwen3-Reranker-4B	https://huggingface.co/Qwen/Qwen3-Reranker-4B

翻译（Translation）

模型名称	模型来源
HY-MT1.5-1.8B	https://huggingface.co/tencent/HY-MT1.5-1.8B

OCR

模型名称	模型来源
PaddleOCR VL	https://huggingface.co/PaddlePaddle/PaddleOCR-VL

计算机视觉（CV）

- 图像分类（Classification）

模型名称	模型来源
MobilenetV2	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/mobilenet/mobilenetv2-12.onnx
Resnet50V2	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/resnet/resnet50-v2-7.onnx

- 目标检测（Detection）

模型名称	模型来源
YOLOv5s	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/yolov5/yolov5s_rknn3.onnx
YOLOv6s	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/yolov6/yolov6s_rknn3.onnx
YOLOv8s	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/yolov8/yolov8s_rknn3.onnx
YOLO26	https://github.com/ultralytics/assets/releases/download/v8.4.0/yolo26s.pt

- 实例分割与姿态估计（Segmentation & Pose）

模型名称	模型来源
YOLO26-Segment	https://github.com/ultralytics/assets/releases/download/v8.4.0/yolo26s-seg.pt
YOLO26-Pose	https://github.com/ultralytics/assets/releases/download/v8.4.0/yolo26s-pose.pt

- 视觉表征（Visual Representation）

模型名称	模型来源
Siglip-so400m	https://huggingface.co/google/siglip-so400m-patch14-384
Siglip2-so400m	https://huggingface.co/google/siglip2-so400m-patch14-384
MetaCLIP2	https://huggingface.co/facebook/metaclip-2-worldwide-m16-384
Dinov3	https://huggingface.co/facebook/dinov3-vits16-pretrain-lvd1689m

- 深度估计（Depth Estimation）

模型名称	模型来源
Depth-Anything-V2	https://huggingface.co/depth-anything/Depth-Anything-V2-Small
Depth-Anything-V3	https://huggingface.co/depth-anything/DA3-BASE

- 机器人操作 (Robot Manipulation)

模型名称	模型来源
GR00T-N1.6-3B	https://huggingface.co/nvidia/GR00T-N1.6-3B
MiniCPM-RobotManip	https://huggingface.co/openbmb/MiniCPM-RobotManip

用户可以从如下网盘获取预先转好的rknn模型。RKNN3_SDK (<https://console.box.lenovo.com/l/H1fig1>, 提取码: rknn)。具体路径如下: RKNN3_SDK/rknn3_models/v1.1.0。

4 模型性能

- LLM 模型性能

模型名称	加速芯片	Input Tokens	New Tokens	TTFT(ms)	TPOT(ms)	Decode TPS
Qwen2.5-0.5B	RK182X	128	128	21.74	4.46	224.19
Qwen2.5-1.5B	RK182X	128	128	47.25	6.60	151.58
Qwen2.5-3B	RK182X	128	128	83.18	9.62	103.97
Qwen2.5-7B	RK1828	128	128	156.94	14.19	70.47
Qwen3-0.6B	RK182X	128	128	27.74	5.42	184.42
Qwen3-1.7B	RK182X	128	128	52.15	7.10	140.89
Qwen3-4B	RK1828	128	128	105.64	11.22	89.14
Qwen3-8B	RK1828	128	128	175.61	16.15	61.92
Qwen3.5-0.8B	RK182X	128	128	56.54	9.21	108.56
Qwen3.5-2B	RK182X	128	128	79.32	10.94	91.40
Qwen3.5-4B	RK1828	128	128	160.56	19.66	50.86
MiniCPM5-1B	RK182X	128	128	35.69	5.72	174.94
HY-MT1.5-1.8B	RK182X	128	128	58.54	8.04	124.37
GLM-Edge-1.5B-Chat	RK182X	128	128	50.43	6.14	162.81

- 多卡级联 LLM 模型性能

模型名称	加速芯片	Input Tokens	New Tokens	TTFT(ms)	TPOT(ms)	Decode TPS
Gemma-4-12B	2x RK1828	5120	128	7576.88	31.85	31.4
Gemma-4-31B	4x RK1828	5120	128	9077.22	70.03	14.28
Qwen3.5-9B	2x RK1828	5120	128	5910.11	30.23	33.08
Qwen3.5-27B	4x RK1828	5120	128	8718.15	76.57	13.06
Qwen3.8-27B	4x RK1828	5120	128	8699.48	76.45	13.08

- VLM 模型性能

模型	加速芯片	Vision分辨率	Vision(ms)	TTFT(ms)	Decode TPS
FastVLM-1.5B	RK182X	512 * 512	167.23	47.14	151.41
InternVL3-2B	RK182X	448 * 448	180.67	47.01	149.77
InternVL3_5-4B	RK1828	448 * 448	175.21	106.09	88.94
Qwen2.5-VL-3B	RK182X	784 * 1176	227.43	93.37	51.23
Qwen2.5-VL-3B	RK1828	392 * 392	216.9	83.16	104.76
Qwen2.5-VL-7B	RK1828	784 * 1176	212.29	156.65	70.20
Qwen3-VL-2B	RK182X	384 * 384	105.57	53.73	147.33
Qwen3-VL-4B	RK1828	384 * 384	108.23	106.92	89.95
MiMo-VL-7B-RL	RK1828	784 * 1176	229.99	165.04	65.31
MiniCPM-V-4	RK1828	448 * 448	234.34	94.37	105.59
SmolVLM-500M-Instruct	RK182X	512 * 512	90.60	27.12	157.16
SmolVLM2-500M-Video-Instruct	RK182X	512 * 512	90.27	27.06	157.43
LocateAnything-3B	RK182X	448 * 448	228.70	92.00	102.80

- 全模态模型性能

模型	加速芯片	Vision分辨率	Vision(ms)	Audio(ms)	TTFT(ms)	Decode TPS
Qwen2.5-Omni-3B (Thinker)	RK1828	392 * 392	217.82	97.37	83.47	104.23
Qwen3-Omni	RK1828	384 * 384	149.40	63.60	112.70	86.20
Qwen3.5-Omni	RK1828	384 * 384	91.20	39.00	157.80	62.30
Gemma-4-E2B	RK182X	384 * 384	55.60	102.88	88.16	75.30
Gemma-4-E4B	RK1828	384 * 384	63.20	104.60	149.35	55.33

• 图像分类模型性能

模型名称	加速芯片	分辨率	单核性能（帧率）	多batch多核性能（帧率）
MobilenetV2	RK182X	224 * 224	287.78	1361.2
Resnet50V2	RK182X	224 * 224	114.15	847.43

• 目标检测模型性能

模型名称	加速芯片	分辨率	单核性能（帧率）	多batch多核性能（帧率）
YOLOv5s	RK182X	640 * 640	35.28	224.26
YOLOv6s	RK182X	640 * 640	30.10	163.24
YOLOv8s	RK182X	640 * 640	34.38	221.79

注：

1. RK182X 表示加速芯片可为 RK1820 或 RK1828。
2. Qwen2.5-VL-3B：
 - 如果使用 RK1820 加速芯片，采用两段式运行方案（LMHead在RK3588上执行）；
 - 如果使用 RK1828 加速芯片，模型推理完全在协处理器端执行。
3. RK1820/RK1828协处理器NPU频率均为1GHz。
4. 测试基于RK3588 + RK1820/RK1828，两者之间通过PCIe连接，RK3588 设置为性能模式。
5. TTFT：模型生成第一个 token 所需的时间。
6. TPOT：生成每个输出 token 所需的平均时间。
7. TPS：模型每秒能生成的 token 数量。
8. VLM 的 Vision 和 LLM 耗时为独立测试，LLM部分的 Input Tokens 和 New Tokens 均设为128。
9. 多卡级联测试基于 RK3588 主控 + 多张 RK1828 协处理器（采用流水线并行级联），RK3588 设置为性能模式。

5 模型精度

• LLM模型精度

模型名称	加速芯片	数据集	原始模型 (float32)	RKNN3 (W4A16 G32)
Qwen2.5-0.5B	RK182X	gsm8k	40.71	36.69
Qwen2.5-1.5B	RK182X	gsm8k	63.08	63.76
Qwen2.5-3B	RK182X	gsm8k	79.91	79.61
Qwen3-0.6B	RK182X	gsm8k	50.72	47.08
Qwen3-1.7B	RK182X	gsm8k	75.36	75.13
Qwen3-4B	RK1828	gsm8k	90.60	90.37
Qwen3.5-4B	RK1828	gsm8k	93.63	92.65

• VLM模型精度

模型名称	数据集	原始模型 (float32)	RKNN3 (W4A16 G32)
FastVLM-1.5B	MMbench(cn)	58.42	60.57
Qwen2.5-VL-3B	MMbench(cn)	76.8	76.37
Qwen2.5-VL-7B	MMbench(cn)	79.98	81.44
InternVL3-2B	MMbench(cn)	77.23	72.51
InternVL3_5-4B	MMbench(cn)	78.69	77.49
MiMo-VL-7B-RL	MMbench(cn)	74.7	70.36

• 图像分类模型精度

模型名称	数据集	原始模型 float32 (TOP1)	原始模型 float32 (TOP5)	RKNN3 模型 W8A8 (TOP1)	RKNN3 模型 W8A8 (TOP5)
MobilenetV2	imagenet	0.694	0.888	0.680	0.882
Resnet50V2	imagenet	0.729	0.911	0.720	0.906

• 目标检测模型精度

模型名称	数据集	原始模型 float32 AP@0.5:0.95	原始模型 float32 AP@0.5	RKNN3 模型 W8A8 AP@0.5:0.95	RKNN3 模型 W8A8 AP@0.5
YOLOv5s	coco2017	0.326	0.481	0.316	0.475
YOLOv6s	coco2017	0.403	0.551	0.386	0.533
YOLOv8s	coco2017	0.39	0.525	0.383	0.517

6 服务器配置推荐

建议的服务器配置及转换耗时参考如下：

模型名称	服务器配置	转换耗时参考
Qwen2.5-0.5B	32 Core CPU / 8 GB 内存 / 1TB 硬盘	约11分钟
Qwen2.5-1.5B	32 Core CPU / 16 GB 内存 / 1TB 硬盘	约26分钟
Qwen2.5-3B	32 Core CPU / 32 GB 内存 / 1TB 硬盘	约52分钟
Qwen2.5-7B	32 Core CPU / 64 GB 内存 / 1TB 硬盘	约105分钟

- 如遇内存不足，可以尝试启用Swap分区扩大内存，参考：<https://wiki.debian.org/Swap>

7 参考

7.1 性能测试方法

- 普通模型性能测试方法

参考：[rknn3-runtime/examples/rknn3_model_test_demo/README_CN.md](#)

- LLM模型性能测试方法

参考：[rknn3-model-zoo/tools/rknn3_llm_test/README.md](#)

7.2 精度测试方法

- 普通模型精度测试

目前rknn3-model-zoo集成了图像分类及目标检测相关的测试方法及代码，用户如果需要复测模型精度，可以参考其中的说明。

1. 分类模型参考: [rknn3-model-zoo/examples/mobilenet_v2/README.md](#)
2. 检测模型参考: [rknn3-model-zoo/examples/yolov8/README.md](#)
3. LLM模型精度测试

rknn3-model-zoo也集成了LLM模型精度测试的方法及代码，支持CMMLU数据集。具体测试参考 [rknn3-model-zoo/tools/rknn3_llm_test/README.md](#)