RKNN3 SDK Release Note

文件标识：RK-JC-YF-429

发布版本：V1.2.0

日期：2026-10-22

文件密级：□绝密 □秘密 □内部资料 ■公开

免责声明

本文档按“现状”提供，瑞芯微电子股份有限公司（“本公司”，下同）不对本文档的任何陈述、信息和内容的准确性、可靠性、完整性、适销性、特定目的性和非侵权性提供任何明示或暗示的声明或保证。本文档仅作为使用指导的参考。

由于产品版本升级或其他原因，本文档将可能在未经任何通知的情况下，不定期进行更新或修改。

商标声明

“Rockchip”、“瑞芯微”、“瑞芯”均为本公司的注册商标，归本公司所有。

本文档可能提及的其他所有注册商标或商标，由其各自拥有者所有。

版权所有 © 2026 瑞芯微电子股份有限公司

超越合理使用范畴，非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

瑞芯微电子股份有限公司

Rockchip Electronics Co., Ltd.

地址： 福建省福州市铜盘路软件园A区18号

网址： www.rock-chips.com

客户服务电话： +86-4007-700-590

客户服务传真： +86-591-83951833

客户服务邮箱： fae@rock-chips.com

读者对象

本文档（本指南）主要适用于以下工程师：

技术支持工程师

软件开发工程师

修订记录

版本	修改人	修改日期	修改说明	核定人
V0.2.0	HPC	2025-08-16	初始版本	熊伟
V0.3.0b0	HPC	2025-09-12	1. 更新支持的模型列表 2. 更新精度、性能数据	熊伟
V0.4.0b0	HPC	2025-11-03	1. 更新支持的模型列表 2. 更新概述、精度、性能数据	熊伟
V1.0.0	HPC	2026-01-23	1. 更新支持的模型列表 2. 更新精度、性能数据	熊伟
V1.0.4	HPC	2026-05-15	1. 更新支持的模型列表 2. 更新精度、性能数据 3. 更新支持的硬件平台	熊伟
V1.1.0	HPC	2026-08-19	1. 更新支持的模型列表 2. 更新精度、性能数据	熊伟
V1.2.0	HPC	2026-10-22	1. 更新主要特性 2. 更新预转换模型网盘路径版本 3. 更新精度、性能数据 4. 更新支持的系统	熊伟

目录

RKNN3 SDK Release Note

1 概述

- 1.1 支持的硬件平台
- 1.2 支持的系统

2 主要特性

3 支持的模型

4 模型性能

5 模型精度

6 服务器配置推荐

7 参考

- 7.1 性能测试方法
- 7.2 精度测试方法

1 概述

RKNN3 SDK提供了AI模型部署到RK1820/RK1828和RK3572所需要的软件栈，包括PC端开发套件（RKNN3 Toolkit）、板端运行API（RKNN3 Runtime）以及模型转换部署示例（RKNN3 Model Zoo）等。本次发布的SDK支持协处理器模式（RK1820/1828）和非协处理器模式（RK3572），两种模式的主要区别如下：

> **[协处理器模式（RK182X）]**

- **主控SoC**：作为系统核心，负责任务调度、资源分配和整体控制
- **RK1820/1828协处理器**：作为AI计算加速单元，专注于高性能神经网络推理任务
- **PCIe/USB高速接口**：实现主控与协处理器之间的低延迟、高带宽数据交互

> **[非协处理器模式（RK3572）]**

- **RK3572 SoC**：集成高性能NPU的SoC平台，支持直接运行AI推理任务
- **统一内存架构**：NPU与CPU/GPU共享内存空间

1.1 支持的硬件平台

- RK1820/RK1828 协处理器
- RK3572

1.2 支持的系统

- Android/Linux/Windows/macOS

2 主要特性

- 新增 MoE（Mixture of Experts）支持
- 新增 PagedAttention（分页注意力）支持
- 新增多 LoRA 权重分离导出支持
- 新增 LLM Grammar（语法约束）输出支持
- 新增从协处理器 eMMC 加载模型支持
- 新增 MatMul 独立调用接口（仅 RK3572）
- 新增 Linux x86_64 协处理器模式、macOS arm64 平台支持
- 新增模型自定义信息查询支持
- 新增 W4BF16 exMatMul 支持
- 新增 Log、ReduceLogSumExp、Tan、Atan、CumSum、LSTM / GRU 等算子支持
- 新增 Windows 平台以太网支持（RK182X 协处理器模式）
- 新增 RKNN3 MCP 模型部署助手（Beta）
- 优化 LUT 激活及指数计算精度
- 优化 Windows USB 通信效率
- 优化 RK3572 大模型支持
- 修复 RK3572 部分场景存在内存泄漏问题
- 修复 Resize、AveragePool、Sub、Transpose、TopK 等算子在部分规格异常问题
- 修复 RK182X 以太网连接稳定性问题

3 支持的模型

目前支持的模型包括但不限于以下列表：

LLM（大语言模型）

模型名称	模型来源
Qwen2.5-0.5B	https://huggingface.co/Qwen/Qwen2.5-0.5B
Qwen2.5-1.5B	https://huggingface.co/Qwen/Qwen2.5-1.5B
Qwen2.5-3B	https://huggingface.co/Qwen/Qwen2.5-3B-Instruct
Qwen2.5-7B	https://huggingface.co/Qwen/Qwen2.5-7B-Instruct
Qwen3-0.6B	https://huggingface.co/Qwen/Qwen3-0.6B
Qwen3-1.7B	https://huggingface.co/Qwen/Qwen3-1.7B
Qwen3-4B	https://huggingface.co/Qwen/Qwen3-4B
Qwen3-8B	https://huggingface.co/Qwen/Qwen3-8B
Qwen3.5-0.8B	https://huggingface.co/Qwen/Qwen3.5-0.8B
Qwen3.5-2B	https://huggingface.co/Qwen/Qwen3.5-2B
Qwen3.5-4B	https://huggingface.co/Qwen/Qwen3.5-4B
Qwen3.5-9B	https://huggingface.co/Qwen/Qwen3.5-9B
Qwen3.5-27B	https://huggingface.co/Qwen/Qwen3.5-27B
Qwen3.8-27B	https://huggingface.co/Qwen/Qwen3.8-27B
Youtu-LLM-2B	https://huggingface.co/tencent/Youtu-LLM-2B
GLM-Edge-1.5B-Chat	https://modelscope.cn/models/ZhipuAI/glm-edge-1.5b-chat
MiniCPM5-1B	https://huggingface.co/openbmb/MiniCPM5-1B
FunctionGemma-270M	https://huggingface.co/google/functiongemma-270m-it
LFM2.5-1.2B	https://huggingface.co/LiquidAI/LFM2.5-1.2B-Instruct
Qwen3-30B-A3B	https://huggingface.co/Qwen/Qwen3-30B-A3B
Qwen3.5-35B-A3B	https://huggingface.co/Qwen/Qwen3.5-35B-A3B
GPT-OSS-20B-A3.6B	https://huggingface.co/openai/gpt-oss-20b
Spark-X2.5	https://huggingface.co/XHToken/Spark-X2.5-4B

VLM（视觉语言模型）

模型名称	模型来源
Qwen2.5-VL-3B	https://huggingface.co/Qwen/Qwen2.5-VL-3B-Instruct
Qwen2.5-VL-7B	https://huggingface.co/Qwen/Qwen2.5-VL-7B-Instruct
Qwen3-VL-2B	https://huggingface.co/Qwen/Qwen3-VL-2B-Instruct
Qwen3-VL-4B	https://huggingface.co/Qwen/Qwen3-VL-4B-Instruct
FastVLM-1.5B	https://github.com/apple/ml-fastvlm
InternVL3-2B	https://huggingface.co/OpenGVLab/InternVL3-2B
InternVL3_5-4B	https://huggingface.co/OpenGVLab/InternVL3_5-4B-Instruct
MiniCPM-V-4	https://huggingface.co/openbmb/MiniCPM-V-4
MiMo-VL-7B-RL	https://huggingface.co/XiaomiMiMo/MiMo-VL-7B-RL
LocateAnything-3B	https://huggingface.co/nvidia/LocateAnything-3B
SmolVLM-500M-Instruct	https://huggingface.co/HuggingFaceTB/SmolVLM-500M-Instruct
SmolVLM2-500M-Video-Instruct	https://huggingface.co/HuggingFaceTB/SmolVLM2-500M-Video-Instruct
UI-TARS-2B-SFT	https://huggingface.co/ByteDance-Seed/UI-TARS-2B-SFT
gme-Qwen2-VL-2B-Instruct	https://huggingface.co/Alibaba-NLP/gme-Qwen2-VL-2B-Instruct
MiniCPM-V-4.7-1B	https://huggingface.co/openbmb/MiniCPM-V-4.7-1B
MiniCPM-V-4.7-35B-A3B	https://huggingface.co/openbmb/MiniCPM-V-4.7-35B-A3B
Mage-VL	https://huggingface.co/microsoft/Mage-VL

全模态模型（Omni）

模型名称	模型来源
Qwen2.5-Omni-3B (Thinker)	https://huggingface.co/Qwen/Qwen2.5-Omni-3B
Qwen3-Omni	商业闭源模型
Qwen3.5-Omni	商业闭源模型
Gemma-4-E2B	https://huggingface.co/google/gemma-4-E2B-it
Gemma-4-E4B	https://huggingface.co/google/gemma-4-E4B-it
Gemma-4-12B	https://huggingface.co/google/gemma-4-12B-it
Gemma-4-31B	https://huggingface.co/google/gemma-4-31B-it

语音识别（ASR）

模型名称	模型来源
Qwen3-ASR-0.6B	https://huggingface.co/Qwen/Qwen3-ASR-0.6B
Whisper	https://huggingface.co/openai/whisper-large-v3
SenseVoiceSmall	https://modelscope.cn/models/iic/SenseVoiceSmall
Zipformer	https://huggingface.co/pfluo/k2fsa-zipformer-chinese-english-mixed
Audio8-ASR-0.1B	https://huggingface.co/Edge0/Audio8-ASR-0.1B
Qwen3-ForcedAligner-0.6B	https://huggingface.co/Qwen/Qwen3-ForcedAligner-0.6B
pyannote speaker-diarization-community-1	https://huggingface.co/pyannote/speaker-diarization-community-1

语音合成（TTS）

模型名称	模型来源
Qwen3-TTS-12Hz-1.7B	https://huggingface.co/Qwen/Qwen3-TTS-12Hz-1.7B-Base
VITS	https://github.com/jaywalnut310/vits

Embedding / Reranker

模型名称	模型来源
Qwen3-Embedding-0.6B	https://huggingface.co/Qwen/Qwen3-Embedding-0.6B
Qwen3-Embedding-4B	https://huggingface.co/Qwen/Qwen3-Embedding-4B
Qwen3-Reranker-0.6B	https://huggingface.co/Qwen/Qwen3-Reranker-0.6B
Qwen3-Reranker-4B	https://huggingface.co/Qwen/Qwen3-Reranker-4B
F2LLM-v2	https://huggingface.co/codefuse-ai/F2LLM-v2-4B
WeMM-Embedding-2B	https://huggingface.co/tencent/WeMM-Embedding-2B

翻译（Translation）

模型名称	模型来源
HY-MT1.5-1.8B	https://huggingface.co/tencent/HY-MT1.5-1.8B

文本分类 / 安全

模型名称	模型来源
openai/privacy-filter	https://huggingface.co/openai/privacy-filter

决策模型

模型名称	模型来源
Intern-Decision-0.8B	https://huggingface.co/internlm/Intern-Decision-0.8B
convaiinnovations/laya	https://huggingface.co/convaiinnovations/laya

OCR

模型名称	模型来源
PaddleOCR VL	https://huggingface.co/PaddlePaddle/PaddleOCR-VL
Unlimited-OCR	https://huggingface.co/baidu/Unlimited-OCR
dots.ocr	https://huggingface.co/dots-studio/dots.ocr
dots.mocr	https://huggingface.co/dots-studio/dots.mocr

计算机视觉（CV）

- 图像分类（Classification）

模型名称	模型来源
MobilenetV2	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/mobilenet/mobilenetv2-12.onnx
Resnet50V2	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/resnet/resnet50-v2-7.onnx

- 目标检测（Detection）

模型名称	模型来源
YOLOv5s	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/yolov5/yolov5s_rknn3.onnx
YOLOv6s	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/yolov6/yolov6s_rknn3.onnx
YOLOv8s	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/yolov8/yolov8s_rknn3.onnx
YOLO26	https://github.com/ultralytics/assets/releases/download/v8.4.0/yolo26s.pt

- 实例分割与姿态估计（Segmentation & Pose）

模型名称	模型来源
YOLO26-Segment	https://github.com/ultralytics/assets/releases/download/v8.4.0/yolo26s-seg.pt
YOLO26-Pose	https://github.com/ultralytics/assets/releases/download/v8.4.0/yolo26s-pose.pt

- 视觉表征（Visual Representation）

模型名称	模型来源
Siglip-so400m	https://huggingface.co/google/siglip-so400m-patch14-384
Siglip2-so400m	https://huggingface.co/google/siglip2-so400m-patch14-384
MetaCLIP2	https://huggingface.co/facebook/metaclip-2-worldwide-m16-384
Dinov3	https://huggingface.co/facebook/dinov3-vits16-pretrain-lvd1689m

- 深度估计（Depth Estimation）

模型名称	模型来源
Depth-Anything-V2	https://huggingface.co/depth-anything/Depth-Anything-V2-Small
Depth-Anything-V3	https://huggingface.co/depth-anything/DA3-BASE

- 机器人操作（Robot Manipulation）

模型名称	模型来源
GR00T-N1.6-3B	https://huggingface.co/nvidia/GR00T-N1.6-3B
GR00T-N1.7-3B	https://huggingface.co/nvidia/GR00T-N1.7-3B
openpi	https://github.com/Physical-Intelligence/openpi
MiniCPM-RobotManip	https://huggingface.co/openbmb/MiniCPM-RobotManip

用户可以从如下网盘获取预先转好的rknn模型。RKNN3_SDK (https://console.box.lenovo.com/l/H1fig1, 提取码：rknn)。具体路径如下：RKNN3_SDK/rknn3_models/v1.2.0。

4 模型性能

- LLM 模型性能

RK1820 / RK1828

模型名称	加速芯片	Input Tokens	New Tokens	TTFT (ms)	Prefill TPS	TPOT (ms)	Decode TPS
Qwen2.5-0.5B	RK182X	128	128	22.44	5704.86	4.47	223.72
Qwen2.5-1.5B	RK182X	128	128	47.85	2674.75	6.69	149.41
Qwen2.5-3B	RK182X	128	128	83.82	1527.12	9.68	103.31
Qwen2.5-7B	RK1828	128	128	157.59	812.25	14.26	70.14
Qwen3-0.6B	RK182X	128	128	28.32	4519.30	5.46	183.13
Qwen3-1.7B	RK182X	128	128	52.60	2433.46	7.15	139.76
Qwen3-4B	RK1828	128	128	106.95	1196.81	11.24	89.00
Qwen3-8B	RK1828	128	128	176.65	724.61	16.26	61.51
Qwen3.5-0.8B	RK182X	128	128	52.88	2420.80	7.44	134.40
Qwen3.5-2B	RK182X	128	128	76.25	1678.58	9.13	109.53
Qwen3.5-4B	RK1828	128	128	154.88	826.45	16.51	60.56
MiniCPM5-1B	RK182X	128	128	33.89	3776.93	5.27	189.89
HY-MT1.5-1.8B	RK182X	128	128	59.37	2156.08	8.11	123.27
GLM-Edge-1.5B-Chat	RK182X	128	128	50.85	2517.31	6.12	163.48

RK3572

模型名称	芯片	Input Tokens	New Tokens	TTFT (ms)	Prefill TPS	TPOT (ms)	Decode TPS
Qwen2.5-0.5B	RK3572	128	128	108.02	1184.94	23.09	43.31
Qwen2.5-1.5B	RK3572	128	128	286.95	446.06	63.93	15.64
Qwen2.5-3B	RK3572	128	128	485.29	263.76	108.32	9.23
Qwen3-0.6B	RK3572	128	128	182.86	699.97	40.49	24.7
Qwen3-1.7B	RK3572	128	128	321.68	397.91	77.09	12.97
Qwen3.5-0.8B	RK3572	128	128	289.16	442.66	51.35	19.47
Qwen3.5-2B	RK3572	128	128	422.64	302.86	92.68	10.79

- 多卡级联 LLM 模型性能

模型名称	加速芯片	Input Tokens	New Tokens	TTFT (ms)	Prefill TPS	TPOT (ms)	Decode TPS
Gemma-4-12B	2x RK1828	5120	128	7636.87	670.43	32.72	30.56
Gemma-4-31B	4x RK1828	5120	128	9153.38	559.36	72.36	13.82

模型名称	加速芯片	Input Tokens	New Tokens	TTFT (ms)	Prefill TPS	TPOT (ms)	Decode TPS
Qwen3.5-9B	2x RK1828	5120	128	5774.10	886.72	26.16	38.22
Qwen3.5/Qwen3.8-27B	4x RK1828	5120	128	8557.89	598.28	70.32	14.22

- MoE 模型性能

模型名称	加速芯片	Input Tokens	New Tokens	TTFT (ms)	Prefill TPS	TPOT (ms)	Decode TPS
Qwen3.5-35B-A3B	5x RK1828	3072	128	2887.19	1064.01	34.65	28.86
Qwen3-30B-A3B	5x RK1828	3072	128	2975.36	1032.48	30.08	33.25
MiniCPM5-15B-A2.5B	3x RK1828	3072	128	4127.97	744.19	24.21	41.30
MiniCPM4.7-35B-A3B	6x RK1828	3072	128	2429.61	1264.40	35.71	28.00

- VLM 模型性能

RK1820 / RK1828

模型	加速芯片	Vision 分辨率	Vision (ms)	TTFT (ms)	Prefill TPS	TPOT (ms)	Decode TPS
FastVLM-1.5B	RK182X	512 * 512	166.69	47.66	2685.86	6.65	150.44
InternVL3-2B	RK182X	448 * 448	181.82	47.84	2675.42	6.75	148.17
InternVL3_5-4B	RK1828	448 * 448	184.49	106.86	1197.85	11.27	88.73
Qwen2.5-VL-3B	RK182X	392 * 392	230.76	94.53	1354.08	19.65	50.90
Qwen2.5-VL-3B	RK1828	392 * 392	216.74	83.95	1524.64	9.60	104.21
Qwen2.5-VL-7B	RK1828	392 * 392	231.44	156.49	817.92	14.32	69.83
Qwen3-VL-2B	RK182X	384 * 384	106.41	54.10	2366.21	6.95	143.95
Qwen3-VL-4B	RK1828	384 * 384	104.22	108.29	1189.47	10.99	90.99
Qwen3.5-4B	RK1828	384 * 384	89.81	154.09	830.68	16.46	60.77
MiMo-VL-7B-RL	RK1828	392 * 392	215.21	165.94	771.35	15.41	64.91
MiniCPM-V-4	RK1828	448 * 448	233.87	95.30	1343.10	9.49	105.34
SmolVLM-500M-Instruct	RK182X	512 * 512	90.61	27.83	4598.53	6.27	159.52
SmolVLM2-500M-Video-Instruct	RK182X	512 * 512	78.02	27.75	4611.95	6.27	159.53
LocateAnything-3B	RK182X	448 * 448	233.17	88.31	1449.44	9.85	101.53

RK3572

模型	芯片	Vision 分辨率	Vision (ms)	TTFT (ms)	Prefill TPS	TPOT (ms)	Decode TPS
Qwen3-VL-2B	RK3572	384 * 384	508.80	319.18	401.03	72.92	13.71

- 全模态模型性能

模型	加速芯片	Vision 分辨率	Vision (ms)	Audio (ms)	TTFT (ms)	Prefill TPS	TPOT (ms)	Decode TPS
Qwen2.5-Omni-3B (Thinker)	RK1828	392 * 392	217.39	98.33	83.73	1528.65	9.65	103.61
Qwen3-Omni	RK1828	384 * 384	138.44	66.19	112.36	1139.20	11.1	90.13
Qwen3.5-Omni	RK1828	384 * 384	89.81	38.49	117.59	1088.53	12.55	79.66
Gemma-4-E2B	RK182X	384 * 384	62.80	96.90	86.92	1472.60	13.31	75.12
Gemma-4-E4B	RK1828	384 * 384	52.88	100.30	159.96	877.36	18.43	54.27

- 图像分类模型性能

模型名称	加速芯片	分辨率	单核性能（帧率）	多batch多核性能 （帧率）
MobilenetV2	RK182X	224 * 224	286.32	1398.1
Resnet50V2	RK182X	224 * 224	113.81	870.5

- 目标检测模型性能

模型名称	加速芯片	分辨率	单核性能（帧率）	多batch多核性能 （帧率）
YOLOv5s	RK182X	640 * 640	35.29	229.95
YOLOv6s	RK182X	640 * 640	30.25	158.73
YOLOv8s	RK182X	640 * 640	34.73	232.61

注：

1. RK182X 表示加速芯片可为 RK1820 或 RK1828。
2. Qwen2.5-VL-3B：
    - 如果使用 RK1820 加速芯片，采用两段式运行方案（LMHead在RK3588上执行）；
    - 如果使用 RK1828 加速芯片，模型推理完全在协处理器端执行。
3. RK1820/RK1828协处理器NPU频率均为1GHz。
4. 测试平台与配置：
    - RK1820/RK1828：测试基于 RK3588 + RK1820/RK1828，两者之间通过 PCIe 连接，RK3588 设置为性能模式。
    - RK3572：采用非协处理器模式，模型直接在 RK3572 本机运行。
5. TTFT：模型生成第一个 token 所需的时间。
6. TPOT：生成每个输出 token 所需的平均时间。
7. TPS：模型每秒能生成的 token 数量。
8. VLM 的 Vision 耗时与 LLM 耗时为独立测试，LLM 部分的 Input Tokens 和 New Tokens 均设为 128。
9. 多卡级联测试基于 RK3588 主控 + 多张 RK1828 协处理器（采用流水线并行级联），RK3588 设置为性能模式。

5 模型精度

- LLM模型精度

模型名称	加速芯片	数据集	原始模型 (float32)	RKNN3 (W4A16 G32)
Qwen2.5-0.5B	RK182X	gsm8k	40.71	37.00
Qwen2.5-1.5B	RK182X	gsm8k	63.08	63.91
Qwen2.5-3B	RK182X	gsm8k	79.91	79.91
Qwen3-0.6B	RK182X	gsm8k	50.72	48.22
Qwen3-1.7B	RK182X	gsm8k	75.36	75.66
Qwen3-4B	RK1828	gsm8k	90.60	89.69
Qwen3.5-4B	RK1828	gsm8k	93.63	92.04

- VLM模型精度

模型名称	数据集	原始模型 (float32)	RKNN3 (W4A16 G32)
FastVLM-1.5B	MMbench(cn)	58.42	59.71
Qwen2.5-VL-3B	MMbench(cn)	76.8	76.20
Qwen2.5-VL-7B	MMbench(cn)	79.98	80.93
InternVL3-2B	MMbench(cn)	77.23	72.77
InternVL3_5-4B	MMbench(cn)	78.69	77.92
MiMo-VL-7B-RL	MMbench(cn)	74.7	70.02

- 图像分类模型精度

模型名称	数据集	原始模型 float32（TOP1）	原始模型 float32（TOP5）	RKNN3 模型 W8A8（TOP1）	RKNN3 模型 W8A8（TOP5）
MobilenetV2	imagenet	0.694	0.888	0.680	0.882
Resnet50V2	imagenet	0.729	0.911	0.720	0.906

- 目标检测模型精度

模型名称	数据集	原始模型 float32 AP@0.5:0.95	原始模型 float32 AP@0.5	RKNN3 模型 W8A8 AP@0.5:0.95	RKNN3 模型 W8A8 AP@0.5
YOLOv5s	coco2017	0.326	0.481	0.316	0.475
YOLOv6s	coco2017	0.403	0.551	0.386	0.534
YOLOv8s	coco2017	0.39	0.525	0.383	0.517

6 服务器配置推荐

建议的服务器配置及转换耗时参考如下：

模型名称	服务器配置	转换耗时参考
Qwen2.5-0.5B	32 Core CPU / 8 GB 内存 / 1TB 硬盘	约11分钟
Qwen2.5-1.5B	32 Core CPU / 16 GB 内存 / 1TB 硬盘	约26分钟
Qwen2.5-3B	32 Core CPU / 32 GB 内存 / 1TB 硬盘	约52分钟
Qwen2.5-7B	32 Core CPU / 64 GB 内存 / 1TB 硬盘	约105分钟

- 如遇内存不足，可以尝试启用Swap分区扩大内存，参考：https://wiki.debian.org/Swap

7 参考

7.1 性能测试方法

- 普通模型性能测试方法

参考：**rknn3-runtime/examples/rknn3_model_test_demo/README_CN.md**

- LLM模型性能测试方法

参考：**rknn3-model-zoo/tools/rknn3_llm_test/README.md**

7.2 精度测试方法

- 普通模型精度测试

目前rknn3-model-zoo集成了图像分类及目标检测相关的测试方法及代码，用户如果需要复测模型精度，可以参考其中的说明。

1. 分类模型参考: **rknn3-model-zoo/examples/mobilenet_v2/README.md**
2. 检测模型参考: **rknn3-model-zoo/examples/yolov8/README.md**
3. LLM模型精度测试

rknn3-model-zoo也集成了LLM模型精度测试的方法及代码，支持CMMLU数据集。具体测试参考 **rknn3-model-zoo/tools/rknn3_llm_test/README.md**