RKNN3 MCP 快速入门

文件标识：RK-JC-YF-440

发布版本：V0.1.0

日期：2026-10-15

文件密级：□绝密 □秘密 □内部资料 ■公开

免责声明

本文档按“现状”提供，瑞芯微电子股份有限公司（“本公司”，下同）不对本文档的任何陈述、信息和内容的准确性、可靠性、完整性、适销性、特定目的性和非侵权性提供任何明示或暗示的声明或保证。本文档仅作为使用指导的参考。

由于产品版本升级或其他原因，本文档将可能在未经任何通知的情况下，不定期进行更新或修改。

商标声明

“Rockchip”、“瑞芯微”、“瑞芯”均为本公司的注册商标，归本公司所有。

本文档可能提及的其他所有注册商标或商标，由其各自拥有者所有。

版权所有 © 2026 瑞芯微电子股份有限公司

超越合理使用范畴，非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

瑞芯微电子股份有限公司

Rockchip Electronics Co., Ltd.

地址： 福建省福州市铜盘路软件园A区18号

网址： www.rock-chips.com

客户服务电话： +86-4007-700-590

客户服务传真： +86-591-83951833

客户服务邮箱： fae@rock-chips.com

前言

概述

本文档是 RKNN3 MCP 的入门指南，涵盖服务接入、部署任务发起、知识库查询及常见问题，帮助用户完成首次配置并开始使用。RKNN3 MCP 当前为 Beta 版本。

读者对象

本文档适用于有模型转换、板端部署等需求的 RKNN3 MCP 用户。

修订记录

版本	修改人	修改日期	修改说明	核定人
V0.1.0	AI团队	2026-10-15	初始 Beta 版本，对齐 RKNN3 Toolkit V1.2.0	熊伟

目录

RKNN3 MCP 快速入门

1 RKNN3 MCP 简介

2 快速开始

2.1 使用前准备

2.2 接入 RKNN3 MCP

2.2.1 接入要求

2.2.2 连接配置

2.2.3 验证连接

2.3 部署示例

2.3.1 基础样例

2.3.2 指定部署阶段

2.3.3 指定功能

2.3.4 极简化部署任务

3 知识库查询

4 常见问题（FAQ）

1 RKNN3 MCP 简介

RKNN3 MCP 是面向瑞芯微 RKNN3 平台的模型部署工作流助手，帮助 AI Agent 将模型分析、ONNX 导出、RKNN3 转换、精度验证和板端部署组织为可追踪、可恢复的任务。它采用客户端执行模式，协作关系如下：

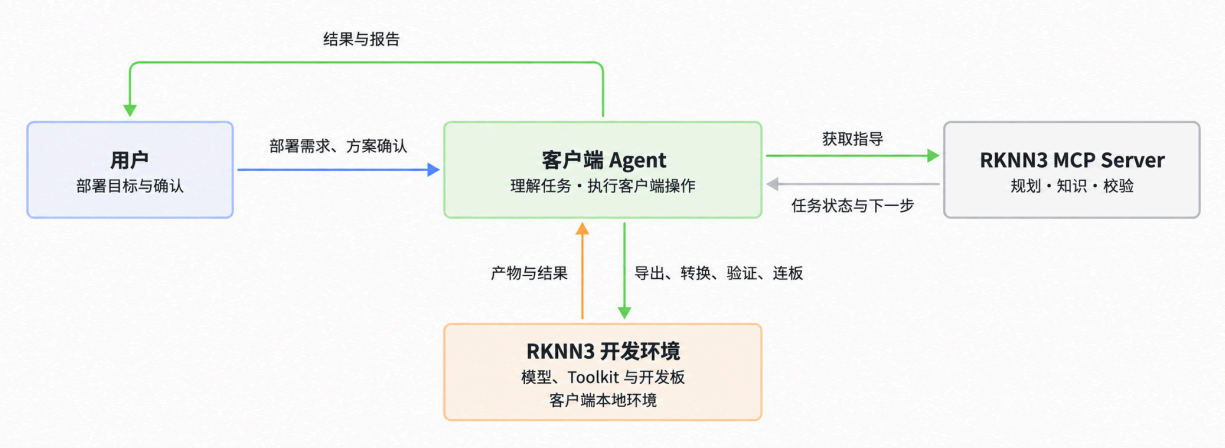


图 1-1 RKNN3 MCP 协作关系

MCP Server 负责部署计划、知识提供、参数校验和任务状态恢复；模型、脚本、RKNN3 Toolkit 与开发板操作均由 Agent 在客户端环境中完成。MCP Server 不读取客户端文件或执行客户端程序，不运行 Python、RKNN3 Toolkit、adb 或板端程序，也不直接连接开发板。

当前工作流覆盖 CNN、ViT、LLM、VLM、ASR 等，目标平台包括 RK1820、RK1828 和 RK3572，并支持 LoRA 转换与部署、多卡部署与推理等功能。MCP 会结合模型与目标平台自动完成部署分析和流程编排；遇到不支持项时，也会明确给出原因和处理建议。

2 快速开始

2.1 使用前准备

使用 RKNN3 MCP 前，请准备模型权重和可访问的工作目录。

如需使用 RKNN3 Toolkit，可参考以下开发环境配置：

操作系统版本	Ubuntu 22.04（x64）	Ubuntu 24.04（x64）	macOS 13+（Apple Silicon）
Python 版本	3.10	3.12	3.10 / 3.12

macOS（Apple Silicon）版 Toolkit 仅支持 ONNX 和现有 LLM 模型的离线转换、构建与导出；不支持板端 Runtime、设备查询、NTP/ADB 传输、性能评估及内存评估，也不提供 Intel Mac 或 Universal2 的 wheel 安装包。

为减少临时下载等待，推荐提前准备以下所需组件，并向 Agent 提供本地路径和版本：

- **RKNN3 Toolkit**：按主机系统、架构和 Python ABI（如 `cp310`）选择同一发布目录中的 wheel 与配套 requirements。
  获取目录：https://github.com/airockchip/rknn3-toolkit/tree/main/rknn3-toolkit
- **RKNN3 Runtime**：涉及板端部署时，准备运行库、配套后端库和通信服务，匹配目标平台、板端系统、架构及部署模式。
  获取目录：https://github.com/airockchip/rknn3-toolkit/tree/main/rknn3-runtime
- **RKNN3 Model Zoo**：按模型和 SDK 版本选择导出、转换及部署示例，可只获取任务所需文件。
  获取仓库：https://github.com/airockchip/rknn3-model-zoo
- **固件（Firmware）**：按实际板型、硬件版本和部署方式选择匹配固件。RK1820 / RK1828 固件可从以下入口获取，其他板型请使用对应板卡厂商的官方发布渠道。
  RK1820 / RK1828 固件地址：https://console.box.lenovo.com/l/PHk0PF

如需上板，建议在开始任务前核对固件、RKNN3 Toolkit 和 Runtime，确保使用同一 SDK 发布套件对应的配套版本；具体对应关系以官方发布说明为准。

如需下载模型、获取参考代码或安装依赖，请确保客户端网络或代理能够访问 GitHub、Python 软件包源等所需资源来源。

2.2 接入 RKNN3 MCP

2.2.1 接入要求

请选择支持远程 MCP 工具调用的 AI 开发工具（以下简称“客户端”）。执行模型转换与板端部署时，Agent 需能够读写工作目录、执行命令，并访问所需的 Python 环境及 RKNN3 组件。涉及板端操作时，还需能够连接开发板。

客户端的安装、登录和模型配置，请参阅所用客户端的官方文档。

2.2.2 连接配置

配置项	内容
服务名称	`rknn3-mcp`

配置项	内容
服务地址	https://rknn-mcp.rock-chips.com/mcp
传输方式	Streamable HTTP（部分客户端显示为 HTTP）

1. 打开客户端的 MCP 配置入口，添加远程 MCP 服务。
2. 按上表填写服务名称、地址和传输方式，并保存配置。
3. 按客户端要求重启客户端或新建会话，使配置生效，并确认该服务及其工具已启用。

具体菜单名称和配置格式可能因客户端而异，请参阅所用客户端的 MCP 接入说明。

2.2.3 验证连接

配置生效后，在客户端的 MCP 管理界面确认服务已启用、工具已加载，然后向 Agent 发送：

```
请检查 rknn3-mcp 是否已连接，并确认其工具是否可用。
本次仅验证连接，不创建部署任务，不执行模型转换。
```

确认服务已连接、工具已加载且可供 Agent 使用后，即可继续第 2.3 节的部署示例。若连接失败或工具不可用，请先检查服务地址、网络及工具启用状态。

2.3 部署示例

使用以下模板时，请将 `<MODEL_PATH>` 等占位符替换为实际值；选填项可按需保留或删除。Python 环境填写 `uv:<VENV_PATH>` 或 `conda:<ENV_NAME>` 中的一种。

2.3.1 基础样例

```
模型权重：<MODEL_PATH>
工作目录：<WORKSPACE_PATH>
Python 环境（选填）：uv:<VENV_PATH> 或 conda:<ENV_NAME>
目标平台：RK1828

请使用 rknn3-mcp，完成模型的 RKNN3 转换。
本次只转换，不上板，不做完整精度分析。
如果 rknn3-mcp 未连接或不可用，请先告知，禁止绕过 MCP 自行执行任务。
```

将上述提示词发送给 Agent 后，Agent 会获取 RKNN3 MCP 的指导，分析模型结构与部署需求，并结合目标平台给出相应的部署方案。

Agent 返回的部署方案示例如下（节选）：



图 2-1 部署方案确认示例（节选）

确认方案前，请重点核对以下内容：

- **目标与阶段范围**：目标平台、执行阶段和停止位置，是否包含上板及精度分析。
- **模型分段与输入**：需转换的分段或子图、各输入尺寸及动态 shape 设置。
- **量化方式与校准材料**：各分段的量化方式，所需校准数据或配置路径及预处理要求。
- **执行环境**：工作目录、Python 环境，以及 Toolkit、Model Zoo 的路径和版本。
- **板卡与运行时参数（需上板时）**：板卡型号、连接方式、Runtime 版本和推理参数。

确认无误后回复“接受”继续。需要调整时，先提出修改，例如：“量化方式改为 `w8a16`”；Agent 展示更新后的方案后，请再次核对并确认。

2.3.2 指定部署阶段

有开发板：ADB 部署

以下模板使用 ADB 连接开发板，完成部署但不执行连板精度分析。ADB 设备标识请填写 USB 设备序列号，或网络连接地址（ `IP:端口` ，例如 `192.168.1.100:5555` ）。

使用网络 ADB 时，Agent 会根据 MCP 指导先建立连接，再执行后续操作。

```
模型权重：<MODEL_PATH>
工作目录：<WORKSPACE_PATH>
Python 环境（选填）：uv:<VENV_PATH> 或 conda:<ENV_NAME>
目标平台：RK1828
连接方式：ADB
ADB 设备标识：<ADB_SERIAL>
GCC 路径：<GCC_PATH>
Model Zoo（选填）：<MODEL_ZOO_PATH>

请使用 rknn3-mcp，完成模型的 RKNN3 部署，不做连板精度分析。
如果 rknn3-mcp 未连接或不可用，请先告知，禁止绕过 MCP 自行执行任务。
```

连板精度分析耗时较长，且会消耗较多 Token；如仅需验证模型能否完成 RKNN3 转换，可使用第 2.3.1 节的基础样例。

无开发板：模拟器精度分析

```
模型权重：<MODEL_PATH>
工作目录：<WORKSPACE_PATH>
Python 环境（选填）：uv:<VENV_PATH> 或 conda:<ENV_NAME>
Model Zoo（选填）：<MODEL_ZOO_PATH>

请使用 rknn3-mcp，完成模型的 RKNN3 模拟器精度分析。
如果 rknn3-mcp 未连接或不可用，请先告知，禁止绕过 MCP 自行执行任务。
```

2.3.3 指定功能

使用 LoRA

使用 LoRA 时，请提供基座模型及其对应的 LoRA 目录。目录中应包含适配器配置文件 `adapter_config.json` 和权重文件 `adapter_model.safetensors` 等配套材料。

```
模型权重：<MODEL_PATH>
LoRA 目录：<LORA_PATH>
工作目录：<WORKSPACE_PATH>
Python 环境（选填）：uv:<VENV_PATH> 或 conda:<ENV_NAME>
目标平台：RK1828
连接方式：ADB
ADB 设备标识：<ADB_SERIAL>
GCC 路径：<GCC_PATH>
Model Zoo（选填）：<MODEL_ZOO_PATH>

请使用 rknn3-mcp，结合上述 LoRA 完成模型的 RKNN3 部署，不做连板精度分析。
如果 rknn3-mcp 未连接或不可用，请先告知，禁止绕过 MCP 自行执行任务。
```

自定义 Paged Attention 页面大小

如需调整 Paged Attention 页面大小，可在提示词中指定页面大小。以下示例将页面大小设置为 512 token。

```
模型权重：<MODEL_PATH>
工作目录：<WORKSPACE_PATH>
Python 环境（选填）：uv:<VENV_PATH> 或 conda:<ENV_NAME>
目标平台：RK1828
连接方式：ADB
ADB 设备标识：<ADB_SERIAL>
GCC 路径：<GCC_PATH>
Model Zoo（选填）：<MODEL_ZOO_PATH>

请使用 rknn3-mcp，将 Paged Attention 的页面大小设置为 512 token，并完成模型的 RKNN3 部署，
不做连板精度分析。
如果 rknn3-mcp 未连接或不可用，请先告知，禁止绕过 MCP 自行执行任务。
```

2.3.4 极简化部署任务

```
模型权重：<MODEL_PATH>
工作目录：<WORKSPACE_PATH>

请使用 rknn3-mcp，帮我将这个模型在 RK1828 的板子上跑起来。
如果 rknn3-mcp 未连接或不可用，请先告知，禁止绕过 MCP 自行执行任务。
```

建议优先使用前文的完整模板，明确模型路径、工作目录、运行环境、开发板信息和部署阶段，减少 Agent 对环境与任务目标的推断。

3 知识库查询

知识库查询是 RKNN3 MCP 提供的一项辅助能力。用户可以通过自然语言向 Agent 查询 RKNN3 相关知识，Agent 会结合 MCP 内置知识库返回对应的技术说明、接口信息和使用建议，例如：

- RKNN3 Toolkit 接口与使用方法；
- rknn3-server 相关配置；
- RKNN3 Runtime 接口与运行机制；
- RKNN3Lite 使用方式。

例如，发送“请使用 rknn3-mcp 查询 RKNN3Lite 的 llm_mode 参数怎么用，并给出简短的 Python 示例”，以下为回答示例（节选）。

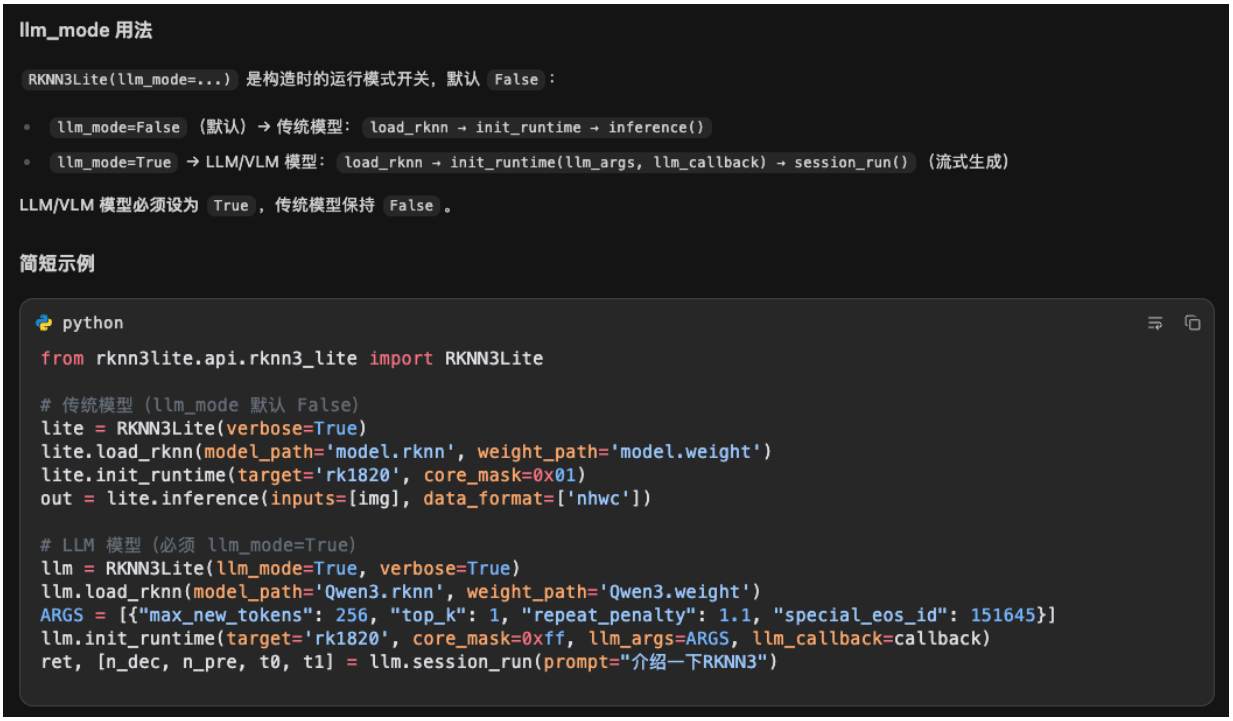


图 3-1 RKNN3Lite 知识库查询示例

4 常见问题（FAQ）

1. 使用 MCP 服务器需要联网吗?

需要。客户端需要联网才能访问 RKNN3 MCP 服务。

2. MCP Server 会上传我的模型或直接操作开发板吗?

不会。模型权重、源码及 RKNN3 Toolkit 保存在用户本地或工作服务器环境中，模型处理与开发板操作由 Agent 在该环境中执行。MCP Server 负责提供部署建议、维护任务流程和校验任务结果，不会读取客户端文件或执行客户端程序。

3. 为什么 Agent 没有调用 RKNN3 MCP?

请先确认 MCP 已连接并已被授权使用。随后在提示词中明确写明“请使用 rknn3-mcp”。如果仍未调用，请让 Agent 说明 MCP 不可用的原因，而不要直接使用其他来源替代。

4. 是否所有模型都能转换为 RKNN3?

不保证。实际结果取决于模型结构、ONNX 图、RKNN3 Toolkit 支持范围、量化方案和目标板端环境。RKNN3 MCP 会先生成部署方案，用户确认后再继续执行。

5. 什么时候需要开发板信息?

仅在需要连板精度分析、板端推理或完整部署时提供。只进行模型分析、ONNX 导出或 RKNN3 转换时，无需提供开发板连接信息。